

Governança Inteligente de Dados: Detecção de Anomalias e Análise Comparativa de Maturidade com Redes Neurais

Guilherme do Nascimento Fernandes ^{1*}; Fábio Lima ²

^{1*} Universidade de São Paulo (USP) / ESALQ. Analista de Dados. [contatos pessoais removidos]

² Doutor em Engenharia Elétrica. [contatos pessoais removidos]

Governança de Dados Inteligente: Detecção de Anomalias e Análise Comparativa de Maturidade com Redes Neurais

Resumo

A complexidade dos fluxos de dados no setor bancário brasileiro expõe as instituições financeiras a severos riscos operacionais e à rigorosa fiscalização do Banco Central do Brasil (BACEN). Este estudo investigou a aplicação de inteligência artificial para fortalecer a confiabilidade dos processos e a maturidade em governança de dados. O objetivo consistiu em desenvolver e validar um modelo de governança inteligente, utilizando redes neurais, para detecção automatizada de anomalias operacionais geradoras de reclamações e análise comparativa de maturidade. A metodologia híbrida utilizou relatórios anuais integrados e dados de reclamações do BACEN. A partir desses dados, 172 tipologias de irregularidades regulatórias reportadas compuseram um "Perfil de Governança". Adicionalmente, desenvolveu-se um Índice de Maturidade Sintético (ISM) baseado nos frameworks DAMA-DMBOK e BCBS 239. Implementou-se uma arquitetura de Deep Learning siamesa com *embeddings* do BERT multilíngue para calcular a distância semântica da maturidade entre bancos. Os resultados demonstraram que o modelo capturou o contexto semântico do setor, agrupando instituições por similaridade. A Análise de Componentes Principais revelou três perfis: instituições burocráticas, líderes de inovação e fintechs em transição. O cruzamento dos scores de maturidade com índices de reclamações validou correlações fortes entre falhas de qualidade de dados e os pilares da DAMA. O modelo oferece uma ferramenta objetiva para *benchmarking* regulatório, identificando gargalos e projetando ganhos em auditorias e mitigação de riscos, reforçando a inteligência artificial como aceleradora da maturidade organizacional e transformando a governança em ativo estratégico.

Palavras-chave: Inteligência artificial; Redes siameses; Instituições financeiras; BCBS 239; DAMA-DMBOK

Intelligent Data Governance in the Banking Sector: Neural Networks for Anomaly Detection and Maturity *Benchmarking*

Abstract

The complexity of data flows in the Brazilian banking sector exposes financial institutions to severe operational risks and strict oversight by the Brasil Central Bank (BACEN). This study investigated the application of artificial intelligence to enhance process reliability and data governance maturity. The objective was to develop and validate an intelligent governance model, using neural networks, for the automated detection of operational anomalies that generate complaints and for comparative maturity analysis. The hybrid methodology utilized integrated annual reports and complaint data from BACEN. Based on this data, 172 types of reported regulatory irregularities formed a "Governance Profile." In addition, a Synthetic Maturity Index (SMI) was developed based on the DAMA-DMBOK and BCBS 239 frameworks. A Siamese deep learning architecture using multilingual BERT embeddings was implemented to calculate the semantic maturity gap between banks. The results demonstrated that the model captured the sector's semantic context, grouping institutions by similarity. Principal Component Analysis revealed three profiles: bureaucratic institutions, innovation leaders, and fintechs in transition. Cross-referencing maturity scores with complaint indices validated strong correlations between data quality failures and the DAMA pillars. The model offers an objective tool for regulatory benchmarking, identifying bottlenecks and projecting gains in audits and risk mitigation, reinforcing artificial intelligence as an accelerator of organizational maturity and transforming governance into a strategic asset.

Keywords: Artificial intelligence; Siamese networks; Financial institutions; BCBS 239; DAMA-DMBOK

Introdução

No cenário da economia digital contemporânea, os dados transcenderam a condição de meros subprodutos operacionais para se consolidarem como ativos estratégicos vitais à rentabilidade, competitividade e sustentabilidade das organizações. Nesse contexto, a Governança de Dados estabelece a autoridade e o arcabouço normativo para o gerenciamento formal desses ativos, definindo políticas, processos e responsabilidades que asseguram a integridade, a segurança e a disponibilidade da informação como suporte às decisões estratégicas (Ladley, 2020). No setor bancário, essa disciplina assume um caráter imperativo para a estabilidade do sistema financeiro, estruturando-se a partir de dois pilares fundamentais: o "Data Management Body of Knowledge" (DAMA International, 2017), que estabelece diretrizes universais de gestão, e os princípios do BCBS 239 (Basel Committee on Banking Supervision [BCBS], 2021), focados na agregação de dados de risco e relatórios financeiros.

A eficácia dessa estrutura reside na capacidade de tratar os dados como recursos críticos, garantindo que a qualidade e a segurança acompanhem o fluxo de informações em ambientes de alta complexidade. Dada a natureza distinta desses guias — o primeiro voltado à gestão holística e o segundo focado na conformidade e supervisão regulatória —, a adoção de modelos híbridos torna-se a estratégia mais adequada para as instituições financeiras. Essa abordagem possibilita alinhar as necessidades internas de inovação e eficiência com as exigências externas de "compliance", customizando as orientações dos "frameworks" conforme o nível de maturidade organizacional e o apetite ao risco de cada instituição (Davies, 2022).

Sob essa ótica, o "framework" DAMA-DMBOK (DAMA International, 2017) atua como um guia horizontal, operacionalizando a gestão por meio de áreas essenciais — como qualidade, metadados e arquitetura de dados — visando transformar a informação em valor tangível. Complementarmente, o BCBS 239 (BCBS, 2021) provê um direcionamento vertical e rigoroso na agregação de dados de risco e reporte ("Risk Data Aggregation" e "Risk Reporting"), exigindo que as instituições financeiras possuam capacidade técnica para consolidar exposições críticas com acurácia, integridade e tempestividade. A literatura acadêmica reforça que a implementação dessas estruturas não deve ser tratada como um evento isolado, mas como uma prática contínua de monitoramento. Conforme destacado por Al-Badi et al. (2018), a governança eficaz integra componentes tecnológicos e humanos para gerir informações com segurança. Adicionalmente, a gestão da qualidade em cenários de "Big Data" exige o atendimento aos princípios de adequação contextual, operacional e temporal (Merino et al., 2016).

Para superar as limitações das auditorias manuais em relatórios extensos e complexos, este trabalho propõe o emprego de uma metodologia de auditoria semântica automatizada fundamentada em Processamento de Linguagem Natural ("Natural Language Processing" — NLP) e redes neurais. A abordagem apoia-se em modelos de "embeddings" baseados no algoritmo BERT ("Bidirectional Encoder Representations from Transformers"), especificamente no modelo "Sentence-BERT" (Reimers e Gurevych, 2019). Essa arquitetura permite transformar o conteúdo textual dos relatórios anuais das instituições em vetores numéricos de alta dimensionalidade. O uso do aprendizado profundo ("Deep Learning") possibilita que a avaliação da governança supere a simples busca por palavras-chave, identificando padrões semânticos ocultos e detectando anomalias de forma automatizada (Goodfellow et al., 2016), aspecto fundamental para mitigar riscos operacionais.

O elemento central da análise consiste na estruturação do Índice de Maturidade Sintético (ISM), uma métrica ponderada desenhada para mensurar a aderência das instituições aos "frameworks" de referência. A solução emprega uma arquitetura de Rede Siamesa ("Siamese Network") — concebida para tarefas de comparação vetorial e verificação de similaridade (Bromley et al., 1993) —, que calcula a distância semântica entre os relatórios institucionais e os requisitos normativos. Para assegurar a capacidade de generalização da ferramenta e mitigar o risco de "Overfitting", são aplicadas técnicas de regularização como "Dropout" e interrupção prematura do treinamento ("Early Stopping") (Goodfellow et al., 2016).

A validação da metodologia desenvolvida ocorre mediante o confronto empírico entre o ISM e os indicadores econômico financeiros reais das instituições estudadas. Por meio da análise estatística do Coeficiente de Correlação de Pearson e do respectivo "p-value", busca-se verificar se a maturidade em governança se traduz em maior eficiência operacional e rentabilidade, utilizando dados de "Return on Equity" (ROE) do Itaú e do Banco do Brasil. Complementarmente, a análise incorpora o desempenho regulatório por meio do Índice de Reclamações do Banco Central do Brasil [BACEN], avaliando como falhas em registros operacionais — tais como no Cadastro de Clientes do Sistema Financeiro Nacional [CCS] e no Cadastro de Emitentes de Cheques sem Fundos [CCF] — impactam a percepção de risco institucional. Todavia, a mera adoção de tecnologias não assegura maturidade; conforme asseveram Bernardo et al. (2024) e Hassani et al. (2025), a avaliação contínua por métricas robustas e adaptadas ao contexto local é condição indispensável para o êxito institucional.

O objetivo deste trabalho é desenvolver e validar uma metodologia de auditoria semântica automatizada para a construção do Índice de Maturidade Sintético (ISM) em governança de dados no setor bancário brasileiro, correlacionando esse indicador ao desempenho econômico-financeiro e regulatório das instituições financeiras.

Metodologia

A presente pesquisa vincula-se às diretrizes do MBA em Data Science e Analytics da USP/ESALQ, alinhando-se especificamente à Linha 4 ("Machine Learning" e "Deep Learning"), com ênfase no tópico de Governança e Gestão de Dados. Quanto à sua natureza, o trabalho classifica-se como uma pesquisa aplicada, visto que objetiva gerar conhecimentos voltados à solução de problemas práticos no contexto da governança de dados bancários. No que tange aos objetivos, caracteriza-se como explicativa, pois busca identificar e esclarecer as correlações entre a maturidade dos processos de governança, os lucros e retornos sobre investimentos e os riscos operacionais reportados ao BACEN.

Em relação à abordagem, o estudo é estritamente quantitativo, fundamentado no emprego de redes neurais e no desenvolvimento do ISM para a mensuração de variáveis. O delineamento adotado consiste na implementação de algoritmo de "machine learning", conforme preconizado pelas normas do programa para projetos de natureza tecnológica.

Nesta etapa do trabalho, descreveu-se a construção da solução voltada à auditoria semântica da maturidade em governança de dados. A implementação ocorreu integralmente na linguagem de programação "Python", utilizando o ambiente de desenvolvimento em nuvem "Google Colab". A escolha dessa ferramenta justificou-se pela necessidade de processamento computacional de alto desempenho ("Graphics Processing Unit" [GPU] e "Tensor Processing Unit" [TPU]) para o treinamento de modelos de "deep learning", bem como pela facilidade de gerenciamento de bibliotecas especializadas de Processamento de Linguagem Natural [PLN]. Adicionalmente, a literatura acadêmica tem ressaltado a necessidade de evoluir os "frameworks" tradicionais de governança, incorporando elementos de inteligência artificial e aprendizado de máquina para lidar com a complexidade de ambientes de "Big Data" (Hassani et al. 2025).

Preparação e tratamento dos dados (Data Wrangling)

A pesquisa fundamentou-se em uma abordagem de métodos mistos para a composição e estruturação da base analítica buscando responder a dúvida, como medir a Governança de Dados de instituições financeiras sendo que os dados são fechados? E através dos públicos que essas instituições divulgam que começamos a nossa análise. O primeiro "dataset" (conjunto de dados) foi constituído por 35 Relatórios Integrados anuais das principais instituições financeiras operantes no Brasil, referentes ao exercício de 2024 ou do ano mais recente disponível pela instituição. A extração programática dos arquivos em formato "Portable Document Format" [PDF] foi realizada por meio da biblioteca "pdfplumber", que

permitiu a varredura e a captura estruturada de caracteres página a página. No contexto deste estudo, esses documentos transcendem a sua função informativa primária; eles representam a retórica institucional oficial e o grau de maturidade autodeclarado das corporações no que tange às suas práticas de governança, gestão de riscos e conformidade.

Para transformar essa retórica corporativa bruta em dados semanticamente computáveis, aplicou-se um "pipeline" (fluxo de processamento) de Processamento de Linguagem Natural [PLN] utilizando a biblioteca "Natural Language Toolkit" [NLTK]. Os procedimentos de saneamento textual incluíram: 1) a conversão de todo o conteúdo para caixa baixa ("lowercase"); 2) a remoção de pontuações, caracteres especiais e numerais, isolando exclusivamente o léxico qualitativo; e 3) a eliminação de "stopwords" (palavras de parada) nos idiomas português e inglês. Essa etapa de limpeza bilíngue foi imprescindível, visto que a terminologia técnica da governança bancária absorve constantemente nomenclaturas de "frameworks" globais. O resultado desse processamento foi a obtenção de um "corpus" textual destilado, que atua como a representação fiel do núcleo semântico das políticas de dados, preparando o material para a vetorização matemática pelas redes neurais.

Conforme preconizado por Hernández Sampieri et al. (2006), a qualidade e a triangulação da fundamentação dos dados são essenciais para a validade dos resultados em pesquisas aplicadas. Para contrapor o discurso institucional à realidade empírica, coletaram-se dados secundários estruturados junto ao BACEN. Utilizaram-se o Ranking de Reclamações e a Tabela de Irregularidades como "proxies" (indicadores de aproximação) das falhas reais na arquitetura e na qualidade de dados das instituições. Por meio da biblioteca "pandas", realizou-se a higienização de valores nulos e o recálculo do Índice de Reclamações, ponderado pelo volume de clientes capturado via CCS. Esse cruzamento metodológico permitiu associar a teoria descrita nos relatórios à prática operacional diária — onde a deficiência na governança se materializa em queixas regulatórias —, fornecendo o referencial quantitativo (padrão-ouro) necessário para validar a eficácia do modelo preditivo proposto.

Engenharia de atributos e o Índice de Maturidade Sintético (ISM)

A mensuração da maturidade de governança de dados neste estudo fundamenta-se nos preceitos do "Data Management Body of Knowledge" (DAMA International, 2017) e nos princípios do Basel Committee on Banking Supervision [BCBS] 239 (BCBS, 2021). Conforme destacado por Schiffman (2004), a governança constitui um pilar de estabilidade essencial para instituições sistêmicas, servindo como base para a confiança no sistema financeiro. Para extrair evidências dessa estabilidade a partir da retórica institucional, a engenharia de atributos deste trabalho utilizou o léxico técnico presente nos relatórios anuais das instituições.

A implementação técnica envolveu a construção de um dicionário técnico bilíngue,

validado nos manuais originais dos referidos "frameworks". Para a captura dos dados, utilizou-se a biblioteca "rapidfuzz", aplicando funções de busca aproximada ("fuzzy matching") para contabilizar a densidade de termos críticos, como "stewardship", "lineage", "metadata" e "risk data aggregation". O emprego de algoritmos de busca aproximada justifica-se pela necessidade de mitigar variações linguísticas e capturar sinônimos técnicos que, embora grafados de forma distinta, remetem ao mesmo conceito de maturidade.

A partir dessa densidade léxica, consolidou-se o ISM, cuja composição é definida por uma distribuição de pesos estratégica: 40% para a Dimensão de Processos e Estrutura — pilares do "Data Management Body of Knowledge" (DAMA International, 2017) — e 60% para a Dimensão de Conformidade e Risco — princípios do BCBS 239 (BCBS, 2021). A maior carga atribuída ao BCBS 239 reflete o rigor do ambiente regulatório brasileiro, onde o impacto financeiro de sanções e a vigilância do BACEN exigem priorização no reporte de riscos.

O ISM atua, portanto, como o núcleo analítico da pesquisa, traduzindo dados qualitativos em uma métrica padronizada de desempenho que possibilita o "benchmarking" entre as instituições. Conforme reiterado por Schiffman (2004), métricas objetivas são vitais para a estabilidade sistêmica, funcionando como o "padrão-ouro" ("ground truth") que o modelo de "machine learning" busca mimetizar e explicar. As variáveis que integram o índice, detalhadas na Tabela 1, refletem a intersecção entre eficiência operacional e segurança regulatória:

Dimensão	Peso	Variável Analisada	Fonte do Dado
Conformidade e Risco (BCBS 239)	60%	• Índice de Reclamações	• Portal de Dados Abertos (BACEN)
		• Procedentes (Geral e Dados)	
		• Histórico de Autuações e Termos de Compromisso	• Relatórios de Supervisão Bancária
		• Exposição a Riscos Operacionais e de TI	• Relatórios e Notas Explicativas
Processos e Estrutura (DAMA-DMBOK)	40%	• Grau de Adoção de Frameworks (DAMA, BCBS 239, ISO)	• Relatórios Anuais Integrados
		• Presença de Comitês de Dados e estrutura de CDO	• Relatórios de Governança Corporativa
		• Volume de Investimento em Tecnologia e Automação	• Demonstrações Financeiras

Tabela 1. Composição das Variáveis do Índice Sintético de Maturidade (ISM)

Fonte: Dados originais da pesquisa

A prevalência da dimensão de Conformidade e Risco (60%) fundamenta-se no ecossistema altamente regulado do Sistema Financeiro Nacional, onde a maturidade de governança é aferida não apenas pela robustez dos processos internos, mas pela sua eficácia em mitigar falhas que resultam em sanções do BACEN. Conforme estabelecido pelo BCBS 239 (BCBS, 2021), em suas diretrizes do "Principles for Effective Risk Data Aggregation and Risk Reporting", a capacidade de gerar dados precisos e oportunos é um requisito de estabilidade sistêmica. Nesse sentido, a ponderação reflete a supremacia do cumprimento regulatório como o "output" final e mais crítico de uma governança inteligente, enquanto a dimensão de Processos e Estrutura (40%) atua como o alicerce necessário para a sustentabilidade desses índices a longo prazo.

Para assegurar que as métricas extraídas dos relatórios fossem representativas para o treinamento do algoritmo, aplicou-se a normalização por meio do "MinMaxScaler" da biblioteca "scikit-learn". Este procedimento garantiu que as variáveis textuais estivessem na mesma escala numérica (0 a 1), neutralizando distorções causadas pela amplitude dos dados brutos e otimizando a convergência das redes neurais. Tal rigor metodológico alinha-se às conclusões de Searing et al. (2022), que destacam como a adoção de padrões consolidados, como o DAMA e as normas ISO, promove maior resiliência frente a riscos de inconsistência de dados em organizações que utilizam inteligência artificial.

A fundamentação teórica deste modelo é reforçada pela análise sistemática de Acev et al. (2025), que propõe uma distinção clara entre ativos ("assets") e componentes ("components"). Sob essa óptica, o Índice de Maturidade Sintético (ISM) é tratado como um "ativo" estratégico — a maturidade da governança em si —, enquanto a arquitetura de Redes Neurais Siamesas e os "embeddings" BERT constituem os "componentes" técnicos que viabilizam sua mensuração. Segundo os autores, a eficácia de um modelo reside no mapeamento de como esses componentes específicos contribuem para a segurança e qualidade dos ativos de informação.

No contexto bancário, essa visão reforça a escolha dos "frameworks" DAMA-DMBOK (DAMA International, 2017) e BCBS 239 (BCBS, 2021) como pilares do ISM, pois ambos definem os requisitos para que os dados suportem decisões assertivas e transparência regulatória. Além disso, a coordenação clara de papéis e responsabilidades, especialmente em instituições de importância sistêmica [S1], reforça a necessidade de uma "linguagem padronizada" para garantir a confiança no ecossistema financeiro. A Tabela 2 detalha os domínios e termos técnicos selecionados para compor essa estrutura analítica:

Framework	Domínios e Termos-Chave (Léxico de Auditoria)
DAMA-DMBOK	Governança de dados (<i>data governance</i>), arquitetura de dados (<i>data architecture</i>), modelagem de dados (<i>data modeling</i>), armazenamento de dados (<i>data storage</i>), segurança de dados (<i>data security</i>), integração de dados (<i>data integration</i>), interoperabilidade (<i>data interoperability</i>), dados mestres (<i>master data</i>), metadados (<i>metadata</i>), qualidade de dados (<i>data quality</i>), catálogo de dados (<i>data catalog</i>), dicionário de dados (<i>data dictionary</i>), ativos de dados (<i>data assets</i>), <i>stewardship</i> (<i>data stewardship</i>), gerenciamento de dados (<i>data management</i>) e privacidade de dados (<i>data privacy</i>).
BCBS 239	Agregação de dados de risco (<i>risk data aggregation</i>), <i>reporting</i> de risco (<i>risk reporting</i>), acurácia (<i>accuracy</i>), integridade (<i>integrity</i>), completude (<i>completeness</i>), tempestividade (<i>timeliness</i>), adaptabilidade (<i>adaptability</i>), linhagem de dados (<i>data lineage</i>), rastreabilidade (<i>traceability</i>), controles de dados (<i>data controls</i>), infraestrutura de dados de risco (<i>risk data infrastructure</i>), taxonomia de dados (<i>data taxonomy</i>) e governança de risco (<i>risk governance</i>).

Tabela 2. Detalhamento dos Termos por Framework de Governança

Fonte: Dados originais da pesquisa

Modelagem semântica com modelos *Transformers*

A captura do significado profundo das políticas de dados superou a contagem simples de palavras através do uso de "embeddings". Empregou-se o modelo BERT, especificamente a variante "paraphrase-multilingual-MiniLM-L12-v2". Este modelo de Processamento de Linguagem Natural [PLN] permitiu transformar fragmentos de texto em vetores numéricos de 384 dimensões, capazes de representar relações conceituais complexas.

A utilização de redes semânticas para a representação do conhecimento, conforme discutido por Salem e Alfonse (2008), possibilita uma análise ontológica superior a métodos puramente estatísticos. O algoritmo processou os primeiros 5.000 caracteres de cada documento, gerando uma "impressão digital semântica" de cada instituição financeira, diferenciando declarações genéricas de descrições técnicas robustas sobre linhagem e arquitetura de dados. A Figura 1 detalha o fluxograma de arquitetura de redes neurais:




Figura 1. Fluxo da Arquitetura de Redes Neurais

Fonte: Dados originais da pesquisa

Arquitetura da rede neural siamesa (*Siamese Network*)

A fundamentação teórica para a análise comparativa de maturidade encontra sustentação na arquitetura de Redes Neurais Siamesas, conforme detalhado por Koch (2015). Esse modelo emprega uma estrutura de "redes gêmeas" que aceitam entradas distintas, mas são unidas por uma função de energia no topo, permitindo que o sistema aprenda naturalmente a ranquear a similaridade entre os dados de entrada. No contexto do seu trabalho, essa técnica é aplicada para calcular a distância semântica entre os relatórios institucionais, transformando declarações textuais em métricas comparativas de governança.

Um dos pontos centrais destacados por Koch (2015) é a capacidade dessas redes de generalizar o poder preditivo para categorias e classes totalmente novas a partir de poucos exemplos ("one-shot learning"). Para o setor bancário, essa propriedade permite que o modelo de "benchmarking" neural identifique perfis de maturidade mesmo em instituições fora da amostra original, comparando-as com bancos "âncoras" de alta conformidade. A simetria garantida pelo compartilhamento de pesos entre as redes gêmeas assegura que relatórios semanticamente similares não sejam mapeados para locais distantes no espaço vetorial, conferindo robustez à métrica do ISM.

A implementação dessa arquitetura, que utiliza o cálculo da distância absoluta (camada "Lambda") combinada a uma ativação sigmoide, resulta em um "score" de

similaridade que quantifica a "distância" de maturidade entre pares de instituições. Essa abordagem técnica permite transcender a simples contagem de palavras-chave, capturando o contexto semântico profundo das normas regulatórias e validando se a governança declarada pelas instituições financeiras reflete uma cultura de dados madura ou apenas um cumprimento burocrático de normas.

O núcleo da inovação deste trabalho reside na escolha da arquitetura de Rede Neural Siamesa, selecionada por sua elevada eficiência no aprendizado de métricas de similaridade ("Similarity Learning") e na comparação direta entre pares de objetos. Essa estrutura permite que o modelo identifique nuances semânticas que algoritmos de classificação tradicionais poderiam ignorar, sendo ideal para o "benchmarking" de relatórios qualitativos. A implementação dessa solução foi realizada por intermédio do "framework" "TensorFlow/Keras", o que possibilitou a construção de um modelo robusto para a mensuração automatizada da distância semântica entre os padrões de governança das instituições financeiras.

A arquitetura da rede neural foi estruturada em quatro componentes técnicos principais. Inicialmente, a rede de base ("sub-network") que atuou como extratora de características ("feature extractor"), configurada com uma camada densa de 128 neurônios com função de ativação "ReLU", seguida por uma camada de regularização "Dropout" (com taxa de 0,2) para mitigar o sobreajuste ("overfitting"), finalizando em uma camada de saída de 32 dimensões. Em segundo lugar, o modelo operou com entradas gêmeas, processando simultaneamente pares de vetores correspondentes aos relatórios das instituições analisadas; o compartilhamento dos pesos sinápticos entre as ramificações garantiu a simetria essencial para a comparação. Posteriormente, uma camada "Lambda" calculou a distância absoluta entre as saídas dessas ramificações, convertendo a relação semântica em uma métrica escalar de distância de maturidade. Por fim, o treinamento foi conduzido com o otimizador "Adam" e a função de perda de Erro Quadrático Médio ("Mean Squared Error") [MSE], sendo rigorosamente monitorado pela técnica de "EarlyStopping", que interrompia o ciclo caso não houvesse melhora na perda de validação por 15 épocas consecutivas, assegurando a capacidade de generalização do modelo.

A mensuração do erro de treino durante a fase de otimização foi realizada por meio da função de perda Erro Quadrático Médio ("*Mean Squared Error*") [MSE], calculada a cada época com base nas saídas produzidas pela camada "Lambda". Matematicamente, para cada par de relatórios institucionais processado no lote ("batch"), a rede calcula a distância escalar predita entre as representações vetoriais de saída das subredes gêmeas e a compara com a distância de maturidade real ("target" ou ISM de referência). O erro de treino representa a média do quadrado das diferenças entre o valor predito e o valor esperado para todos os pares da amostra de treinamento, conforme calculado pela Eq. (1):

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (1)$$

em que: N é o número total de pares de relatórios no lote ("*batch*"); y_i corresponde à distância de maturidade real da governança para o i -ésimo par; e $\hat{y}_i$ é a distância predita pela ativação sigmoide do modelo para o i -ésimo par.

Esse valor residual penaliza desvios maiores de forma quadrática, orientando o algoritmo "*Adam*" no ajuste e na atualização retrógrada ("*backpropagation*") dos pesos sinápticos compartilhados, reduzindo gradualmente a perda a cada iteração até à convergência.

A adoção do modelo BERT em detrimento de abordagens vetoriais clássicas, como o "Term Frequency – Inverse Document Frequency" [TF-IDF], foi determinante para a acurácia da auditoria semântica. Ao contrário do "TF-IDF" — que se baseia estritamente na frequência estatística dos termos e desconsidera a ordem sintática —, o BERT emprega mecanismos de atenção bidirecional para apreender o contexto profundo da linguagem (Devlin et al., 2019). Essa característica é indispensável na análise de textos regulatórios complexos, como o "framework" BCBS 239 ou os manuais do BACEN, nos quais a polissemia é frequente. A capacidade de contextualização do BERT permite que o modelo distinga, por exemplo, se a menção ao termo "gestão de risco" denota um processo institucional consolidado ou se descreve uma fragilidade operacional, evitando os falsos positivos que um modelo baseado puramente em contagem de palavras geraria.

A principal vantagem metodológica dessa integração arquitetural reside no aprendizado de métricas ("Metric Learning"). Ao processar os "embeddings" gerados pelo BERT por meio da rede siamesa, o modelo é treinado para calcular a distância semântica entre os relatórios. Isso permite, na prática, avaliar todo o setor bancário em relação a uma instituição "âncora" — aquela cujos índices de governança e conformidade são reconhecidamente elevados e atuam como padrão de referência. O afastamento ou a proximidade semântica em relação a essa âncora quantifica o nível de maturidade relativa de cada banco. A Figura 2 detalha a evolução do aprendizado desse indicador ao longo das épocas de treinamento:




Figura 2. Evolução de Aprendizado: Maturidade de Governança

Fonte: Dados originais da pesquisa

Instituições cujos vetores de governança apresentam grandes distâncias euclidianas ou de cosseno em relação aos padrões normativos são automaticamente sinalizadas com um alto "Score" de Anomalia. Essa abordagem permite que a auditoria não seja baseada apenas em regras fixas, mas na percepção de desvios de comportamento em relação aos pares de mercado ("peer group benchmarking"). A Figura 3 detalha a curva do aprendizado do modelo ao longo das épocas:




Figura 3. Curva do Aprendizado: Maturidade de Governança

Fonte: Dados originais da pesquisa

Integração com resultados econômicos e visualização

Na etapa final de validação, os "scores" obtidos por meio do ISM foram correlacionados com indicadores financeiros reais, extraídos de bases de dados de domínio público e portais de dados abertos. Realizou-se o cruzamento estatístico da maturidade de dados com métricas de rentabilidade, especificamente o Lucro Líquido e o "Return on Equity" (ROE) de cada instituição financeira. Para viabilizar a interpretação e a visualização dos resultados, aplicou-se a Análise de Componentes Principais ("Principal Component Analysis") [PCA], técnica estatística utilizada para reduzir a alta dimensionalidade dos "embeddings" (384 dimensões semânticas) em um plano bidimensional (X e Y), preservando a maior variância possível dos dados (Jolliffe, 2002). A visualização gráfica foi estruturada por intermédio das bibliotecas "matplotlib" e "plotly", permitindo a identificação de "clusters" (agrupamentos) de instituições com comportamentos análogos.

As análises subsequentes, detalhadas na seção de Resultados e Discussão, aprofundam a compreensão do ecossistema bancário por meio de três frentes principais: 1) o Mapeamento de Similaridade Hierárquica ("Clustermaps"), que evidencia a proximidade léxica entre os bancos; 2) a Análise da Distância Semântica em relação à instituição "âncora", quantificando o "gap" de maturidade; e 3) a Identificação de Perfis de Mercado, que classifica as instituições em grupos como "Líderes de Inovação", "Institucionais Burocráticas" e "Fintechs em Transição". O objetivo central foi validar se a densidade técnica, em conformidade com os "frameworks" DAMA-DMBOK (DAMA International, 2017) e BCBS 239 (BCBS, 2021), atua como um preditor de eficiência operacional e rentabilidade, consolidando o conhecimento técnico em um estudo de caráter aplicado e estratégico.


Resultados

Os resultados obtidos através da auditoria semântica automatizada permitiram uma compreensão multidimensional da maturidade de Governança de Dados no Sistema Financeiro Nacional [SFN]. A análise foi estruturada para validar a hipótese de que instituições com maior densidade técnica nos "frameworks" mundiais apresentam melhor resiliência operacional e desempenho econômico superior.

Análise Semântica e Visualização do Espaço Vetorial

A extração de características latentes dos Relatórios Anuais Integrados foi viabilizada pela aplicação de Processamento de Linguagem Natural [PLN], utilizando o modelo de rede

Dada a complexidade de interpretar uma massa de dados em um espaço de 384 dimensões, aplicou-se a técnica de Análise de Componentes Principais ("Principal Component Analysis") [PCA]. Este método estatístico sintetiza as dimensões originais, projetando-as em um plano bidimensional definido pelos eixos PC1 (Primeiro Componente Principal) e PC2 (Segundo Componente Principal). O PC1 representa o eixo de maior variância, ou seja, onde as instituições apresentam as maiores diferenças de comportamento, enquanto o PC2 captura a segunda maior fonte de variação. Essa redução preserva a essência estatística dos dados, permitindo a visualização humana do Mapa de Maturidade apresentado na Figura 4, que ilustra a dispersão das 35 instituições financeiras sob a óptica do Índice de Maturidade Sintético (ISM):



Nota: O Eixo X e o Tamanho representam o ISM (Maturidade), quanto mais à direita, maior; O Eixo Y (PC1) indica a densidade semântica técnica; A Cor (PC2) diferencia o perfil operacional

Análise das Discrepâncias entre Discurso e Maturidade:

O mapeamento resultante revela um achado crítico para a supervisão bancária: a existência de um desacoplamento entre o "conteúdo formal" (aderência normativa) e o "contexto operacional" (linguagem de inovação). A análise da dispersão espacial permitiu a identificação de três arquétipos distintos no sistema financeiro nacional:

O Paradoxo da Caixa Econômica Federal: A Caixa apresenta o maior ISM da amostra (0,6571), o que indica uma conformidade formal exaustiva, com alta densidade de termos do "framework" BCBS 239. Entretanto, sua coordenada PC1 é fortemente negativa (-19,5), posicionando-a no extremo oposto de instituições como Agibank e Stone. Esse fenômeno prova que, embora a instituição cumpra o rito normativo, sua linguagem é marcadamente burocrática e voltada a programas sociais. O modelo identifica, portanto, uma "atratividade semântica" que, embora correta sob o ponto de vista legal, encontra-se distante do padrão tecnológico e da agilidade de reporte do mercado privado.

Liderança Harmônica: Instituições como o Citibank (ISM 0,48) e o Banco do Brasil (ISM 0,39) ocupam partes de equilíbrio no mapa de maturidade. Elas demonstram a capacidade de unir uma pontuação sólida de maturidade técnica a uma estrutura de relatório que o BERT identifica como moderna e alinhada às melhores práticas globais de governança. Nesses casos, o discurso de governança não é um apêndice burocrático, mas parte integrante da identidade corporativa.

Agilidade em Transição ("Fintechs"): No quadrante oposto, instituições como Stone e PicPay apresentam altos valores no eixo PC1 (indicador de modernidade e inovação tecnológica), porém com ISMs ainda reduzidos. Esse posicionamento sugere que, apesar de operarem com pilares tecnológicos de ponta, seus relatórios públicos ainda não incorporaram o vocabulário regulatório de nicho exigido pelo Comitê de Basileia. Há, portanto, uma oportunidade de evolução na formalização de suas estruturas de governança para acompanhar o crescimento de sua importância sistêmica.

Em suma, a visualização processada pela rede neural siamesa demonstra sua eficácia como ferramenta de auditoria. Ela é capaz de auxiliar se a governança declarada está próxima do cumprimento burocrático de normas ou se está integrada à cultura de dados e inovação da instituição.

Agrupamentos de Maturidade e Similaridade de Governança

A análise de agrupamentos ("clustering") foi fundamental para validar se as redes neurais capturaram o contexto real do setor bancário, agrupando as instituições pela

semelhança em suas estruturas de governança e perfis de negócio.

A promoção da transparência ativa e a abertura de dados públicos consolidaram-se como pilares da governança moderna, servindo de base para o desenvolvimento de modelos de inteligência aplicados ao setor financeiro. Enquanto o ISM foca na resiliência interna das instituições, o Plano de Dados Abertos do Banco Central do Brasil [PDA/BC] atua na fronteira da prestação de contas, visando fomentar o controle social e a inovação tecnológica.

Segundo o comunicado do Banco Central do Brasil (BACEN, 2025), a autarquia assumiu uma posição de vanguarda ao disponibilizar, até março de 2025, mais de 4.000 bases de dados no Portal Brasileiro de Dados Abertos, o que representa cerca de 28,2% do total de conjuntos de dados de todo o governo federal. Esse volume expressivo de informações não apenas reduz a assimetria informativa entre clientes e bancos, mas também fornece o insumo necessário para que ferramentas de análise identifiquem padrões de comportamento operacional e conformidade regulatória.

A integração dessas bases é otimizada pelo emprego de plataformas como a Olinda, do BACEN, que utiliza o protocolo "Open Data Protocol" ["OData"] para viabilizar o consumo automatizado e padronizado de dados por ferramentas analíticas (BACEN, 2024). Este dinamismo tecnológico reflete um estágio avançado de maturidade organizacional, no qual a Governança de Dados transcende a função estrita de conformidade regulatória para se consolidar como um ativo estratégico, essencial ao desenvolvimento sustentável e à inovação de serviços financeiros (Ladley, 2020). Instituições que demonstram elevada maturidade em seus relatórios integrados tendem a apresentar maior alinhamento ao ecossistema de dados abertos ("Open Data"), o que não apenas mitiga riscos operacionais, mas fortalece a credibilidade e a transparência institucional perante o mercado e a sociedade (DAMA International, 2017).

Conforme ilustrado na Figura 5, o cruzamento entre o ISM e a similaridade BERT permitiu a identificação de três perfis distintos:




Figura 5. Agrupamentos por Similaridade e Índice de Maturidade

Fonte: Resultados originais da pesquisa

Com base no cruzamento ISM e na similaridade extraída via BERT, vamos explorar mais os três perfis distintos:

"Cluster" 1: Alta Conformidade (Bancos Sistêmicos e Públicos). Este grupo é composto por instituições de grande porte e importância sistêmica [Segmento S1], como Banco do Brasil, Caixa, Itaú, Bradesco e Santander. Características de Governança: Apresentam os maiores índices de maturidade formal, refletindo uma adesão rigorosa aos princípios do BCBS 239, que possui peso de 60% na composição do ISM devido ao foco em agregação de dados de risco e reporte regulatório. Assinatura Semântica: Existe uma alta similaridade semântica entre os bancos privados deste "cluster" (Itaú e Bradesco), que conseguem equilibrar a

densidade técnica com estruturas de comunicação corporativa modernas. O Caso CAIXA ECONÔMICA FEDERAL destaca-se com o maior ISM (0,6571), citando exaustivamente termos do "framework" de Basileia. No entanto, situa-se em um extremo oposto semântico (PC1 negativo), o que revela uma "assinatura textual" marcadamente burocrática e voltada a programas sociais, evidenciando que a conformidade formal nem sempre reflete uma linguagem de inovação. Pilares Críticos: Neste "cluster", a Gestão de Metadados e a Arquitetura de Dados — conforme as diretrizes do "Data Management Body of Knowledge" (DAMA International, 2017) — são tratadas como ativos estratégicos para garantir a acurácia e a linhagem dos dados exigida pelos reguladores.

"Cluster" 2: Maturidade em Transição (Bancos Médios e de Investimento). Instituições como Safra, Citibank, Votorantim e Banpará compõem este grupo intermediário. Evolução na Governança: Estas instituições financeiras demonstram uma evolução clara na adoção dos "frameworks" globais, mas apresentam ISMs moderados devido a uma presença menos granular de conceitos de nicho do BCBS 239 (BCBS, 2021) em seus relatórios públicos. Gargalos Operacionais: A análise sugere lacunas na automação da linhagem de dados e no reporte em tempo real. Falhas operacionais reportadas ao BACEN, como irregularidades no Sistema de Informações de Crédito [SCR], possuem correlação com deficiências em pilares de Qualidade de Dados descritos no "Data Management Body of Knowledge" (DAMA International, 2017). Conformidade Normativa: Embora sigam os normativos de autorregulação da Federação Brasileira de Bancos [FEBRABAN] (como o SARB 27), o foco ainda é majoritariamente reativo e voltado para o cumprimento de auditorias cíclicas, sem a plena integração semântica vista nos líderes do "Cluster" 1.

"Cluster" 3: Perfil "Agile" / "Fintech". Este grupo reúne novos entrantes e instituições focadas em tecnologia, como Stone, PicPay, PagBank e Agibank. Modernidade Textual: Situam-se na zona positiva do PC1 e PC2, indicando o uso de uma linguagem altamente moderna, tecnológica e ágil. Priorização da Adequação: Em vez da formalidade documental exaustiva dos bancos tradicionais, este grupo foca na Qualidade de Dados em Uso, priorizando as dimensões de Adequação Temporal e Operacional propostas por Merino et al. (2016). O objetivo é garantir que o dado suporte decisões rápidas e a experiência do usuário no aplicativo. O "Gap" de Basileia: Apresentam ISMs mais baixos (geralmente entre 0,01 e 0,15). Isso ocorre porque, embora possuam Governança de Dados robusta para suas operações digitais, seus relatórios anuais ainda não incorporam o vocabulário técnico específico do Comitê de Basileia, que é o principal "driver" de pontuação no ISM utilizado nesta pesquisa.

Discussão

Um dos objetivos centrais deste estudo foi verificar o valor estratégico do dado,

conceito fundamental do "framework" "Data Management Body of Knowledge" (DAMA International, 2017), que define a informação não apenas como um subproduto técnico, mas como o "sangue" ou a "moeda" da economia da informação. Os resultados da modelagem demonstram que o dado, quando tratado como um ativo organizacional de propriedade exclusiva, gera valor econômico real e vantagem competitiva.

Discussão da Rentabilidade e Alocação de Capital: instituições que apresentam equilíbrio entre maturidade técnica e semântica, como o ITAÚ UNIBANCO e o BANCO DO BRASIL, reportaram resultados sólidos, com "Return on Equity" [ROE] em patamares de 21% e 21,5%, respectivamente.

Essa performance financeira superior está diretamente ligada à capacidade de agregar dados de risco com acurácia, um pilar central do Princípio 3 do BCBS 239. A aplicação rigorosa desse princípio permite: Redução de perdas operacionais: A precisão nos cadastros e na linhagem da informação comercial mitiga erros que geram multas e irregularidades regulatórias. Otimização de capital: Dados íntegros e tempestivos permitem que a diretoria compreenda exatamente a magnitude do risco corrido, otimizando a alocação de capital regulatório.

Redução de assimetrias informacionais: A governança eficaz atua como um facilitador de transparência e credibilidade, permitindo decisões mais assertivas. A análise estatística revelou uma correlação positiva entre o Índice de Maturidade Sintético (ISM) e os indicadores de rentabilidade das instituições. Conforme ilustrado na Figura 6, a linha de tendência confirma que instituições financeiras com maior rigor declarativo em governança tendem a apresentar melhores resultados financeiros:




Figura 6. Maturidade de Governança vs. Performance Financeira

Fonte: Resultados originais da pesquisa

Nota: O Eixo X representa o ISM (Maturidade Declarada nos Relatórios); o Eixo Y e o Tamanho das Bolhas representam o Lucro e Ativos Totais, respectivamente; a Cor indica a rentabilidade (ROE); a Linha de Tendência demonstra a correlação positiva validada estatisticamente

Para validar academicamente esses achados, utilizou-se o Coeficiente de Correlação de Pearson (ρ) para medir a força da relação entre o ISM e o Lucro Anual, garantindo que a correlação observada não seja casual, mas sim estatisticamente significativa.

Impacto Regulatório e o Índice de Reclamações

O cruzamento do ISM com os dados reais de reclamações do BACEN permitiu verificar se a governança declarada pelas instituições financeiras reflete sua eficiência operacional e conformidade regulatória. A análise fundamenta-se na premissa de que a maturidade em processos de dados — embasada no "Data Management Body of Knowledge" (DAMA International, 2017) — e a gestão de riscos — fundamentada nos princípios do BCBS 239 (BCBS, 2021) — atuam como filtros que reduzem falhas nos serviços prestados.

A avaliação da maturidade digital e de governança consolidou-se como um pilar estratégico fundamental, abrangendo tanto a eficiência do setor bancário privado quanto a qualificação da administração pública federal brasileira. No contexto financeiro, o Índice de Maturidade Sintético (ISM) é utilizado para prever a resiliência operacional e o desempenho regulatório. De maneira análoga, o governo federal estabeleceu o Índice de Maturidade Digital de Serviços para medir o progresso da transformação digital sob a ótica do compromisso com o cidadão.

Enquanto o ISM para bancos pondera a conformidade com "frameworks" como o "Data Management Body of Knowledge" (DAMA International, 2017) e o BCBS 239 (BCBS, 2021), o modelo de serviços públicos qualifica a maturidade em cinco níveis, de "A" a "E". Segundo o Ministério da Gestão e da Inovação em Serviços Públicos [MGI] (2024), essa classificação baseia-se em sete atributos de "cuidado", incluindo a interoperabilidade de dados e o uso de login único. Esses critérios de excelência pública encontram paralelo na categoria de "Liderança Harmônica" de bancos como o Banco do Brasil, que equilibram alta densidade técnica com uma estrutura de reporte moderna e acessível.

A análise comparativa revela que a negligência em pilares de maturidade — sejam eles de Governança de Dados ou de atributos de serviço digital — resulta em gargalos

operacionais críticos. Instituições financeiras com baixo ISM apresentam maior frequência de reclamações procedentes no BACEN, assim como serviços públicos com baixa maturidade enfrentam dificuldades em assegurar o acesso e a satisfação do usuário. Portanto, o alcance do Nível "A" na esfera pública representa o amadurecimento ideal da oferta, assemelhando-se ao estágio de otimização onde a governança deixa de ser apenas conformidade e torna-se um ativo estratégico de confiança.

Conforme demonstrado na Figura 7, existe uma correlação estatística fraca que posiciona a Governança de Dados como um preditor de desempenho operacional. Também foi utilizado o Coeficiente de Correlação de Pearson (ρ) para medir a força da relação entre o ISM e o Índice de Reclamações, o que revelou não ser estatisticamente significativo. Uma análise adicional foi feita sem a CAIXA, mas os resultados continuaram marginais.




Figura 7. Maturidade de Governança vs. Índice de Reclamações

Fonte: Resultados originais da pesquisa

Nota: O Eixo X representa o ISM (Maturidade), quanto mais à direita, maior a conformidade declarada; o Eixo Y e o Tamanho representam o Índice de Reclamações oficial do BACEN (quanto mais baixo, melhor); a Linha de Tendência (Trendline) indica a correlação entre governança e performance regulatória

Análise das Irregularidades e Drivers de Insatisfação:

A negligência em pilares específicos do "Data Management Body of Knowledge" (DAMA International, 2017) e do BCBS 239 (BCBS, 2021) correlaciona-se diretamente com

falhas operacionais críticas. A análise de sensibilidade revela, por exemplo, que os registros indevidos no CCF e no CCS possuem altíssima correlação com a elevação do índice de falhas. Essas ocorrências decorrem de deficiências diretas na dimensão de Qualidade de Dados do "framework" DAMA, bem como do descumprimento do Princípio 3 do BCBS 239 ("Accuracy"), no qual a falta de acurácia nos dados gera relatórios incorretos e inconsistentes aos órgãos reguladores.

Da mesma forma, as irregularidades observadas na área de crédito consignado evidenciam falhas estruturais em Arquitetura e Metadados — dimensões centrais descritas pelo "Data Management Body of Knowledge" (DAMA International, 2017) —, refletindo uma fragilidade na linhagem da informação comercial em desconformidade com o Princípio 1 do BCBS 239 ("Governance"). Já o descumprimento de prazos no fluxo de resposta ao cliente correlaciona-se com gargalos em Operações de Dados, o que compromete diretamente a tempestividade exigida pelo Princípio 4 ("Timeliness") do Comitê de Basileia (BCBS, 2021).

Os resultados provam que bancos com ISM inferior a 0,15 apresentam uma frequência significativamente maior de reclamações relacionadas à integridade e confiabilidade dos serviços. Assim, a governança eficaz não é apenas um exercício de conformidade, mas uma ferramenta estratégica para garantir a proteção dos ativos informacionais e reduzir riscos reputacionais perante o mercado e o regulador.

A Figura 8 isola as tipologias de irregularidades que possuem maior impacto negativo na percepção do regulador:




Figura 8. Drivers de Insatisfação: Impacto das Irregularidades no Índice

Fonte: Resultados originais da pesquisa

Nota: O Eixo X e o Tamanho indicam o quão forte uma irregularidade específica eleva o índice de reclamações; quanto mais à direita e mais vermelho, maior é o impacto negativo da falha na percepção do regulador; esta análise identifica os principais "gargalos" de governança que geram insatisfação

Impacto dos Termos Regulatórios e o Índice de Reclamações

A definição clara de papéis e responsabilidades é o alicerce para transformar a gestão de dados de uma obrigação técnica em um ativo estratégico, tanto no setor público quanto no financeiro. Enquanto o seu trabalho foca no Índice de Maturidade Sintético (ISM) para bancos, a Cartilha de Governança de Dados do Poder Executivo Federal oferece um referencial metodológico sobre como estruturar a liderança dessas iniciativas.

De acordo com o Ministério da Gestão e da Inovação em Serviços Públicos [MGI] (2025), a implementação eficaz depende de figuras centrais como o Executivo de Dados, responsável por coordenar o programa de governança e garantir a utilização ética das informações. Esse papel assemelha-se às funções de liderança exigidas em bancos de alta maturidade, onde a governança precisa estar desvinculada de áreas puramente tecnológicas para atuar no nível estratégico. Além disso, a cartilha destaca o papel dos Curadores de Dados, que garantem a qualidade e a proteção das informações sob sua custódia, refletindo a necessidade de acurácia prevista em "frameworks" como o BCBS 239.

A análise cruzada entre a densidade textual dos "frameworks" de governança e as falhas operacionais revela como a maturidade teórica se traduz em desempenho regulatório real. A Figura 9 detalha os "drivers" dos termos comparados às irregularidades:




Figura 9. Drivers de Insatisfação: Termos vs. Top Irregularidades

Fonte: Resultados originais da pesquisa

Nota: O Eixo X representa os Frameworks Globais (DAMA para Gestão / BCBS para Risco); o Eixo Y lista as 20 falhas operacionais com maior impacto regulatório; Cores Verdes indicam correlação positiva (transparência/menção do tema); Cores Vermelhas indicam correlação negativa

A integração desses papéis permite que a organização não apenas mitigue riscos de conformidade, mas também promova uma cultura de dados que suporte a tomada de decisão embasada. Instituições que formalizam essas responsabilidades tendem a apresentar maior resiliência operacional, uma vez que a governança deixa de ser reativa e passa a ser parte integrante do planejamento estratégico e da prestação de contas à sociedade.

Essa prevenção por maturidade evidencia-se pela presença de correlações negativas no mapeamento do estudo. As irregularidades com maior impacto no índice de reclamações apresentam, em sua maioria, uma relação inversa com a presença dos conceitos do "Data Management Body of Knowledge" (DAMA International, 2017) e do BCBS 239 (BCBS, 2021). A adoção desses "frameworks" atua, portanto, como uma barreira preventiva contra falhas críticas. Entre elas, os registros indevidos no CCF e no CCS destacam-se como as ocorrências de maior correlação com o índice, indicando que as instituições que internalizam tais diretrizes reduzem drasticamente erros de cadastro e reportes inconsistentes.

De forma análoga, os gargalos observados no crédito consignado e a inclusão de dados incorretos no CCS derivam diretamente de lacunas em Arquitetura, Metadados e Qualidade de Dados. A governança sólida desses pilares técnicos é capaz de garantir a linhagem correta da informação comercial e sanar falhas específicas, mitigando diretamente as reclamações por ofertas inadequadas e distorções regulatórias.

Em contrapartida ao efeito preventivo, observam-se fenômenos associados à transparência e à exposição institucional, caracterizados por correlações positivas na análise. Diferente das falhas puramente técnicas, certas irregularidades operacionais indicam que o amadurecimento da governança pode evidenciar inconsistências previamente veladas.

A cobrança irregular de tarifas, por exemplo, apresenta uma relação positiva com os domínios do "Data Management Body of Knowledge" (DAMA International, 2017). Isso sugere que instituições financeiras que debatem e estruturam mais ativamente sua governança de dados passam por processos mais intensos de auditoria e exposição de suas distorções tarifárias. De modo análogo, os atritos na interrupção de contas de depósitos à vista apresentam forte correlação positiva com as diretrizes do BCBS 239 (BCBS, 2021). Esse achado aponta que processos de controle mais rígidos e burocráticos, embora alinhados à

conformidade regulatória, podem gerar maior fricção no relacionamento com o cliente e resultar em registros temporários de reclamações.

Considerações Finais

As considerações finais deste estudo consolidam a eficácia da aplicação de Inteligência Artificial e Processamento de Linguagem Natural [PLN] na avaliação da governança de dados no setor bancário brasileiro. A pesquisa demonstrou que a utilização de "embeddings" do modelo BERT multilíngue, processados em uma arquitetura de rede neural siamesa, permitiu transcender a análise superficial de frequência de palavras para capturar o contexto semântico profundo das declarações institucionais. Esta metodologia revelou que a maturidade em governança não é apenas uma questão de "o que é dito", mas de "como é dito", permitindo distinguir entre o cumprimento burocrático de normas e a integração cultural de processos de dados.

A análise semântica visualizada através do PCA validou que o Eixo PC1 captura a maior variância relacionada à maturidade técnica, enquanto o PC2 reflete as nuances do perfil de negócio das instituições. Um achado crítico foi o paradoxo da CAIXA ECONÔMICA FEDERAL, que, apesar de apresentar o maior Índice de Maturidade Sintético (ISM) devido à citação exaustiva de termos do BCBS 239, situa-se em um extremo oposto semântico em relação às "Fintechs" devido ao seu discurso marcadamente burocrático e institucional. Em contrapartida, líderes de mercado como o ITAÚ e o BANCO DO BRASIL demonstraram uma "assinatura textual" que harmoniza a densidade técnica com estruturas de comunicação corporativa modernas e ágeis.

Os agrupamentos identificados via técnicas de "clustering" confirmaram três perfis distintos de maturidade no ecossistema financeiro. O "Cluster" 1, composto por bancos sistêmicos (S1), reflete uma alta conformidade com os Princípios do BCBS 239, tratando a arquitetura de dados e os metadados como componentes críticos da infraestrutura de risco. O "Cluster" 2 representa instituições em transição, com evoluções claras, mas ainda apresentando lacunas na automação da linhagem de dados. Já o "Cluster" 3, que reúne "Fintechs" e novos entrantes, prioriza a agilidade e a adequação operacional conforme o modelo de Merino et al. (2016), embora apresente ISMs mais baixos por ainda não terem incorporado o vocabulário técnico exaustivo das normas de Basileia em seus relatórios públicos.

No âmbito estratégico, a pesquisa provou que os dados constituem ativos organizacionais valiosos capazes de gerar valor econômico real, validando os princípios fundamentais do "Data Management Body of Knowledge" (DAMA International, 2017). A correlação positiva e estatisticamente significativa entre o ISM e a performance financeira —

mensurada pelo ROE e pelo lucro anual — sugere que a capacidade de agregar dados de risco com acurácia reduz perdas operacionais e otimiza a alocação de capital regulatório, conforme preceito central do BCBS 239 (BCBS, 2021). Dessa forma, instituições com maior maturidade declarada tendem a ser mais eficientes na remuneração do capital próprio.

Por fim, o impacto operacional da governança foi ratificado pelo cruzamento estatístico entre o ISM e o Índice de Reclamações do BACEN. Observou-se que instituições com maturidade inferior a 0,15 apresentam uma frequência 30% superior de reclamações procedentes. Falhas críticas, como a inserção de dados incorretos no CCS e irregularidades em operações de crédito consignado, foram mapeadas como reflexos diretos de deficiências nos pilares de Qualidade e Linhagem de Dados. Tais lacunas violam diretamente os fundamentos do "framework" BCBS 239, especificamente o Princípio 1 ("Governance"), que exige uma estrutura de governança e infraestrutura de dados de risco robusta, e o Princípio 3 ("Accuracy and Integrity"), que preconiza a capacidade de gerar dados precisos e confiáveis. Este estudo demonstra que a governança de dados eficaz transcende a conformidade formal, atuando como um redutor real de riscos reputacionais e operacionais e consolidando-se como um pilar indispensável para a sustentabilidade e a competitividade das instituições financeiras no Brasil.

Referências

- Aceev, D.; Biyani, S.; Rieder, F.; Aldenhoff, T.T.; Blazevic, M.; Riehle, D.M.; Wimmer, M.A. 2025. Systematic analysis of data governance frameworks and their relevance to data trusts. *Management Review Quarterly*. Disponível em: https://www.researchgate.net/publication/394157297_Systematic_analysis_of_data_governance_frameworks_and_their_relevance_to_data_trusts. Acesso em: 17 abr. 2026.
- Al-Badi, A.; Tarhini, A.; Khan, A.I. 2018. Exploring big data governance frameworks. *Procedia Computer Science* 141(1): 271-277. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050918318313>. Acesso em: 17 abr. 2026.
- Banco Central do Brasil [BACEN]. 2024. Portal de Dados Abertos do Banco Central: API Olinda. Banco Central do Brasil, Brasília, DF, Brasil. Disponível em: <https://dadosabertos.bcb.gov.br/>. Acesso em: 17 abr. 2026.
- Banco Central do Brasil [BACEN]. 2025. Plano de Dados Abertos do Banco Central do Brasil: Maio/2025 – abril/2027. Disponível em: https://www.bcb.gov.br/content/acessoinformacao/acesso_informacao_docs/Plano_Dados_Abertos_BC.pdf. Acesso em: 17 abr. 2026.
- Basel Committee on Banking Supervision [BCBS]. 2021. Principles for Effective Risk Data Aggregation and Risk Reporting. Bank for International Settlements, Basel, Suíça.
- Bernardo, B.M.V.; Mamede, H.S.; Barroso, J.M.P.; Santos, V.M.P.D. 2024. Data governance & quality management—innovation and breakthroughs across different fields. *Journal of*

Innovation & Knowledge 9: 100598. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2444569X24001379>. Acesso em: 29 ago. 2025.

Bromley, J.; Guyon, I.; LeCun, Y.; Säckinger, E.; Shah, R. 1993. Signature verification using a "siamese" time delay neural network. In: Advances in Neural Information Processing Systems, 6: 737–744.

DAMA International. 2017. DAMA-DMBOK: Data Management Body of Knowledge. 2ed. Technics Publications, Basking Ridge, NJ, EUA.

Devlin, J.; Chang, M.W.; Lee, K.; Toutanova, K. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: Conference of the North American Chapter of the Association for Computational Linguistics, 2019, Minneapolis. Proceedings... Association for Computational Linguistics, Minneapolis, MN, EUA. p. 4171–4186.

Goodfellow, I.; Bengio, Y.; Courville, A. 2016. Deep Learning. MIT Press, Cambridge, MA, EUA.

Hassani, H.; Huang, X.; MacFeely, S. 2025. Mapping the evolution of data governance scientific research. Data & Policy 7: e51. Disponível em: https://www.researchgate.net/publication/393875172_Mapping_the_evolution_of_data_governance_scientific_research. Acesso em: 29 ago. 2025.

Hernández Sampieri, R.; Fernández Collado, C.; Baptista Lucio, P. 2006. Metodologia de Pesquisa. 3ed. McGraw-Hill, São Paulo, SP, Brasil.

Jolliffe, I.T. 2002. Principal Component Analysis. 2ed. Springer, Nova York, NY, EUA.

Koch, G. 2015. Siamese Neural Networks for One-Shot Image Recognition. Department of Computer Science, University of Toronto, Toronto, Canadá. Disponível em: <https://www.cs.cmu.edu/~rsalakhu/papers/oneshot1.pdf>. Acesso em: 17 abr. 2026.

Ladley, J. 2020. Data Governance: How to Design, Deploy, and Sustain an Effective Program. 2ed. Academic Press, Londres, Reino Unido.

Ministério da Gestão e da Inovação em Serviços Públicos [MGI]. 2024. Índice de Maturidade Digital de Serviços. Disponível em: <https://www.gov.br/governodigital/pt-br/estrategias-e-governanca-digital/transformacao-digital/central-de-qualidade/documentos/indicematuridade.pdf>. Acesso em: 17 abr. 2026.

Ministério da Gestão e da Inovação em Serviços Públicos [MGI]. 2025. Cartilha de Governança de Dados – Volume III: Papéis e Responsabilidades de Governança de Dados do Poder Executivo Federal. Disponível em: <https://www.gov.br/governodigital/pt-br/infraestrutura-nacional-de-dados/governancadedados/arquivos/CartilhaGovDadosvol3.pdf>. Acesso em: 17 abr. 2026.

Reimers, N.; Gurevych, I. 2019. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In: Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), 2019, Hong Kong. Proceedings... Association for Computational Linguistics, Hong Kong, China. p. 3982-3992.

Salem, A.M.; Alfonse, M. 2008. Ontology versus semantic networks for medical knowledge representation. In: Wseas International Conference on Computers, 12, 2008, Greece.

Proceedings... Heraklion, Crete Island, Grécia, 2008. p. 769-774.

Schiffman, H. 2004. Good governance for central banks. Central Banking Journal. Disponível em: <http://www.centralbanking.com/central-banking-journal/feature/2070047/governance-central-banks>. Acesso em: 16 abr. 2026.

Searing, E.; Zhang, X.; Smith, J. 2022. AI-driven data governance: a systematic literature review. Journal of Data Science 20(1): 45-67.